

An 88.36TOPS/W Bit-Level-Weight-Compressed LLM Accelerator Cluster-Aligned INT-FP-GEMM and Bi-Dimensional Workflow Reformulation 改进意见

关于利用动态稀疏性和在线学习的方式适应多种输入数据的改进意见

本文通过ABAF编码，CAMP-PE中将activation进行指数相似性聚类和数据流调度等方式完成对LLM的加速，但是在动态适应不同输入数据的情况下仍然存在以下短板：

- ABAF是相对固定的压缩方式，是一个静态编码，在不同输入数据下难以保持相关性能的稳定；
- CAMP-PE中的聚类可能无法适应指数相差很大的极端数据情况；
- 尽管已经提出了BMSR和三向数据流调度减少PE的等待时间，但是不同的计算阶段仍然可能因数据分布不均导致PE负载不均衡，影响计算效率。

改进建议1：动态稀疏性调整

- 重要性感知剪枝：受*MultCIM: Digital Computing-in-Memory-Based Multimodal Transformer Accelerator With Attention-Token-Bit Hybrid Sparsity* 中RTP机制的启发，可以在运行时监测weight和activation的显著性，对于不显著的项可以省去计算过程。
- 自适应的KV缓存处理：对KV-cache中的近期信息保留较多ABs，对较远的历史信息正常限制ABs甚至从KV-cache中移除（较远的历史信息对当前token的生成影响不大）。

改进建议2：在线学习的参数调整

上面的不显著数据的判断，近期信息/历史信息判定可以静态给出，但是动态变化的控制参数可能更加符合对不同输入的适应性的需求，因此可以引入在线学习机制，预测计算，优化资源分配。

可以通过建立在线学习机制，对：数据显著性判断，KV-cache中的信息保留和压缩，CAMP-PE的动态聚类，BMSR的PE队列深度和数据流向控制等进行动态学习，实现对不同输入数据的适应。

验证方式

对于利用动态稀疏性进行调整的部分，可以将原加速器和加入动态调整的加速器在不同模型，不同输入数据的条件下进行仿真和测试，比较能效比，计算效率等指标；

对于利用在线学习机制动态调整相关参数的部分，在实际电路上部署RL代理，实现动态调整参数，对比静态参数和动态参数电路的性能指标。

AWSC以及BMSR精度分析的改进意见

在CAMP-PE中，由于直接对activation进行移位会导致位宽改变，增加计算复杂度和能耗，于是将指数对齐的移位操作作用于weight，即AWSC，通过移位weight简化计算，只要ABs没有发生变化，那么只需进行zero-extension而不需要扩充位宽也不影响计算结果。

然而在当前的论文中，在此处的**精度是否能够保障**方面存在分析尚不明确的环节，如：

- 对weight的移位是否真的可以通过zero-extension进行完美的替代？是否能够在某固定位宽和ABs的条件下始终保持数值等价？
- 在实际电路中是否可能出现饱和，截断，溢出等问题影响计算精度？
- 是否提供了精度保护机制？

类似的问题在**BMSR**也有体现，即利用taylor展开和horner法则将非线性函数转化为线性函数计算时，没有给出近似阶数，误差范围，以及是否会产生激活函数分布偏移，attention权重失衡，影响模型精度等对模型稳定性产生影响的定量分析。

因此，我在这个方面提出了一些改进意见。

改进建议：进行理论误差边界分析

对于AWSC，通过理论分析明确指出在使用多少位精度（比如， $\text{INT} \times \text{weight} (<< a)$ 和 $\text{INT} (<< a) \times \text{weight}$ 在各个位宽下会产生多大误差，在实际位宽配置中可能会产生的误差上下限。

对于BMSR，分析不同非线性函数在常见激活范围内展开x项的误差上下限；

给出关于这两个改进可能产生的误差是可接受的论证。

进行精度误差测试

通过模拟或者在实际电路上进行误差精度测试来验证分析。

对于AWSC，通过实际测试对比AWSC 和 baseline 的输出误差，并提取关键指标如L1/L2误差进行分析；

对于BMSR，需应用于不同模型的各个对非线性计算敏感的位置如attention层进行计算测试，观察计算结果是否会出现注意力失衡或者函数输出分布漂移等异常情况，同时引入观测指标观察结果是否在可接受范围内。

优化电路保护设计

明确电路可以支持的位宽。对于计算过程中可能出现的溢出，截断等现象，设置相关保护和处理逻辑。

实际实验步骤（以对AWSC的改进为例）

1. 建立支持AWSC和传统计算方式的电路，在相同输入的情况下观察计算结果，评估AWSC的精度变化；
2. 在小模型中逐层加入AWSC，观察计算结果的精度变化，token输出是否受到影响。
3. 画出相关曲线便于分析参考。